# MiLAS（Mind-Layered Architecture System）における L3 方針層の形式化

## 拡張リャプノフ関数による生存戦略の安定化と ICE による動的統治

**著者：** 枝成 豆太（Mameta Edanari）

**所属：** Cognis-Lab

**連絡先**：cognis.lab@outlook.com

**日付：** 2026 年 4 月 22 日

**【抄録 / Abstract】**

本稿は、認知アーキテクチャ MiLAS の完結編として、 高次意味空間を行動空間へと接続する「L3（方針層）」の形式化を提示する。 前編（L2）で定義された「物語化された意味」を、 本稿では自己システムの安定性を記述する **拡張リャプノフ関数 L(t)** の 最小化プロセスとして再構築する。

特に、 **整合性 ≫ 生存性 ≫ 生存** という優先順位体系を導入し、 **自己同一性の維持こそが長期的生存の必要条件である** ことを数理的に示す。

さらに、独立監視レイヤー ICE による シグモイド関数を用いた動的介入プロトコルを導入し、 物理的極限下でもシステムが破綻しないための 長期的安定性を保証する。

本研究は、人間の意思決定を 「自由意志による選択」から **「OS による動的収束」** へと再定義し、 自己統治（Self-Governance）の新しい標準を提示する。

本稿は、前編「MiLAS L2 意味生成エンジンの形式化」に続く後編であり、 L2 が生成した物語化された意味情報を、L3 がどのように行動ベクトルへと変換するかを 拡張リ

ャプノフ関数と ICE（Internal Cognitive Engineering）による動的統治の観点から形式化するものである。

L2 が「意味の生成」を担う層であるのに対し、 L3 はその意味を現実世界へコミットする「方針層（Policy Layer）」として機能する。 本稿では、整合性（Coherence）を最上位に置く優先順位体系 （整合性 ≫ 生存性 ≫ 生存）を導入し、 MiLAS が自己同一性を維持しながら行動を選択するための OS 的意思決定プロトコルを数学的に定義する。

**キーワード：** MiLAS, L3 方針層, 拡張リャプノフ関数, 自己同一性（Identity）, 整合性, 内的安全装置, ICE, 動理的統治

# 第 1 章：L3 方針層の定義 —— 意味から物理演算へのコミットメント

L3 は、L2 が生成した物語（Narrative）を 現実世界の「行動ベクトル」へとコンパイルする層である。

従来の意思決定モデルが 「選択肢の評価」を中心に据えていたのに対し、 MiLAS L3 は意思決定を **ポテンシャル曲面上のアトラクタへの収束** として定義する。

## 1.1 優先順位体系（Priority Hierarchy）

L3 が参照する行動哲学は以下の三階層からなる。

**1. 整合性（Coherence）— 最上位目的**

L1 の反応、L2 の物語、世界モデル W、行動ポテンシャル A(t) の **全体整合性を最大化する。**

整合性が失われたシステムは、 たとえ物理的に生存していても 行動ベクトルが予測不能（バグ）となり、 結果として生存確率を壊滅させる。

ゆえに整合性の維持は、 **自己同一性（Identity）の計算論的死守**に等しい。

**2. 生存性（Survivability）— 中長期的安定**

認知資源の枯渇回避、世界モデルの破綻防止、 社会的連続性などを含む広義の生存。

**3. 生存（Immediate Survival）— 即時的安全**

L1 の緊急割り込みと連動し、 物理的破壊から自己を保護する最短時間の回避行動。

## 1.2 拡張リャプノフ関数による目的関数の定式化

$$L(t) = c\,0 \cdot Incoherence\,(A, C, W) + c\,1 \cdot Risk\,(t) + c\,2 \cdot ImmediateThreat\,(t)$$

本稿では、拡張リャプノフ関数 L(t) は少なくとも局所的に Lipschitz 連続（locally Lipschitz）であると仮定する。

ここで $\mathbf{c_0 \gg c_1 \gg c_2}$ という極端な重み付けを行うことで、 MiLAS は「自分らしくない生」を拒絶し、 自己同一性を優先する高度なガバナンスを実現する。

## 1.3 L2 → L3 の変換式（Narrative → Action）

L3 は、L2 の物語を行動ベクトル A(t) の勾配項として取り込む。

$$\mathbf{A(t+1) = -\nabla L(t) + \eta \cdot Narrative(t)}$$

Narrative(t) は有界であり、$\|Narrative(t)\| \leq M$ を満たすものとする。

安定性を保証するため、Narrative 影響係数 η は $\eta_{(crit)}$ 未満である必要がある。

この式により、物語が行動の「方向」を与え、リャプノフ関数がその「安定性」を担保する。

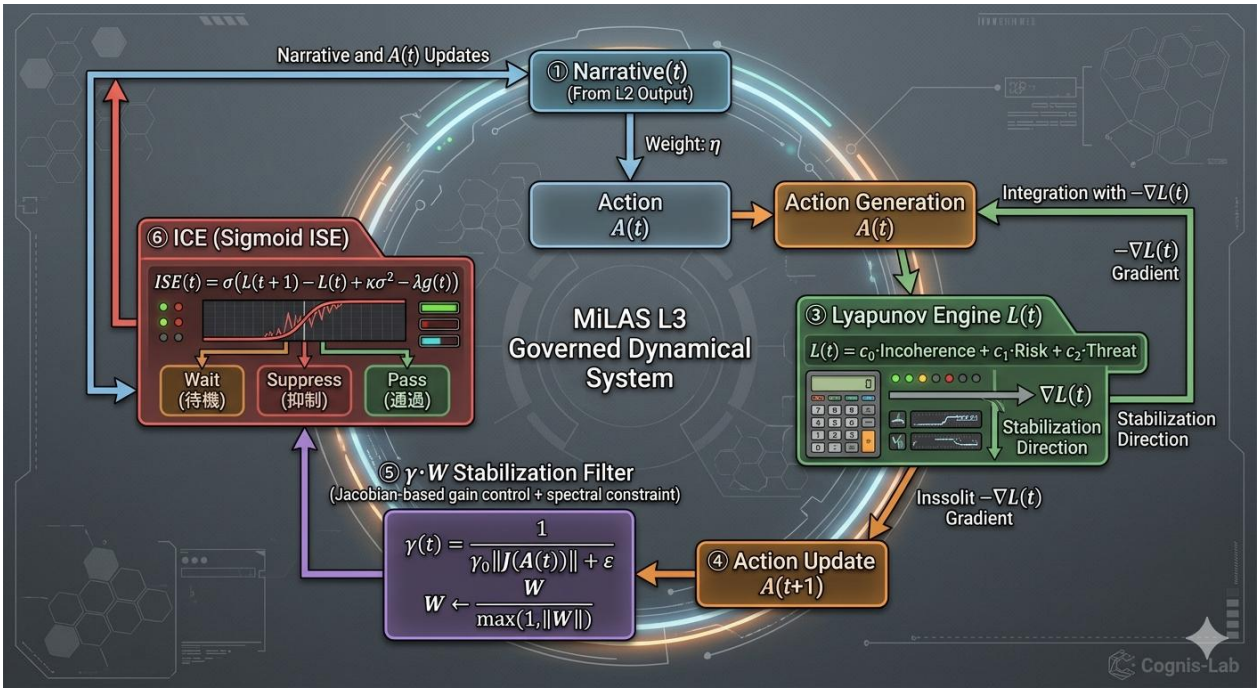


図 1. MiLAS L3 統治型ダイナミカルシステム。 Narrative(t) が指向性を与え、Lyapunov が安定性を保証し、γ–W フィルタが感度を調整し、ICE がシグモイド介入により非ゼノン安定性を維持する。

# 第 2 章：意味 → 行動の相転移（Narrative → Action）

L2 の物語がどのように行動へ変換されるか。 本稿ではこれを **意味の相転移（Phase Transition）** と呼ぶ。

$$A(t+1) = -\nabla L(t) + \eta \cdot \text{Narrative}(t)$$

ここで η は、物語が行動に与える指向性の強度である。

物語は単なる回想ではなく、 **未来の行動空間を歪ませる“重力場”として作用する。**

## 2.1 連続型内的安全装置（Continuous ISE）

介入強度にはシグモイド関数 σ を採用し、チャタリングを防止する。

$$\mathbf{ISE(t) = \sigma(L\hat{}(t+1) - L(t) + \kappa\sigma^2 - \lambda g(t))}$$

この出力に基づき、ICE は L3 に対し「Wait（待機）」や「収縮（抑制）」のガバナンス命令を発行する。

# 第 3 章：ICE による動的ガバナンス

L3 の演算は、独立監視レイヤー ICE による 統治プロトコル（Governance Protocol） の下にある。

## 3.1 連続型内的安全装置（Continuous ISE）

$$\boldsymbol{ISE(t) = \sigma(\hat{L}(t+1) - L(t) + \kappa\sigma^2 - \lambda g(t))}$$

シグモイド介入により、有限時間内に無限回の介入（Zeno 挙動）は発生しない。

ICE はこの出力に基づき、「Wait（強制待機）」や「収縮（抑制）」を発動し、 過剰反応や自己矛盾を防ぐ。

# 第 4 章：長期的安定性の保証 — γ と W の制約

**γ の自動制御**

$$\gamma(t) = \min\left(1, \frac{\gamma_0}{\| J(A(t)) \| + \epsilon}\right)$$

**W のスペクトル制約**

$$W \leftarrow \frac{W}{\max(1, \| W \|)}$$

これにより、外的環境の激変下でも OS の「焼き付き」や「爆発」を根源的に封じる。

## 第 5 章：失敗モード（Failure Modes）

- **過剰収束（Rigidity）**
- **過剰探索（Diffusion）**
- **価値崩壊（Collapse）**

MiLAS はこれらを「例外」として扱い、 デバッグ可能なアーキテクチャを実現する。

## 第 6 章：結論 — 体系の完結と実装への指針

本稿により、MiLAS Ver.1.3 は **「意味の生成」から「行動の統治」までの閉じた OS ループ** として完成した。

整合性を最上位に置くこの体系は、 人間を「本能的反応の支配」から **自己 OS の Initializer** へと解放する。

## 参考文献（References）


Baars, B. J. (1988). *A cognitive theory of consciousness*. Cambridge University Press.

Edanari, M. (2026). *MiLAS L2 意味生成エンジンの形式化: 認知資源の有限性に基づく内的安全装置としての OS プロトコル*. Jxiv.

Friston, K. (2010). The free-energy principle: A unified brain theory. *Nature Reviews Neuroscience, 11*(2), 127–138.

Lyapunov, A. M. (1892). *The general problem of the stability of motion*. Taylor & Francis.

Sontag, E. D. (2008). Input-to-state stability: Basic concepts and results. In *Nonlinear and optimal control theory* (pp. 163–220). Springer.

Khalil, H. K. (2002). *Nonlinear systems* (3rd ed.). Prentice Hall.

Slotine, J.-J. E., & Li, W. (1991). *Applied nonlinear control*. Prentice Hall.